

CE en Desarrollo de Aplicaciones en Lenguaje Python

Proyecto Final Intermodular — Proyecto 3

MANUAL DE USUARIO

Clasificador de Estado de Salud mediante ML

Alumno/a: Salvador Martínez Bolinches

IES Font de Sant Lluís | Curso 2025–2026

1. Descripción de la aplicación

Este programa predice si un paciente tiene riesgo de diabetes a partir de indicadores biomédicos. El usuario solo necesita ejecutar un único script Python que realiza todo el proceso de forma automática: carga los datos, los limpia, genera gráficas de análisis, entrena dos modelos de clasificación y muestra los resultados en pantalla.

2. Requisitos del sistema

2.1 Software necesario

Componente	Versión mínima	Notas
Python	3.9	Comprobar con: <code>python3 --version</code>
pip	21.0	Gestor de paquetes de Python
Git	2.0	Solo necesario para clonar el repositorio
Conexión a internet	—	Solo para la primera ejecución (descarga del dataset)

2.2 Librerías Python

Librería	Versión mínima
numpy	1.24
pandas	2.0
matplotlib	3.7
scikit-learn	1.3

3. Instalación paso a paso

3.1 Clonar el repositorio

Abre una terminal y ejecuta:

```
git clone https://github.com/SalvaIES/P3_clasificador_salud_ml.git
cd P3_clasificador_salud_ml
```

3.2 Crear entorno virtual (recomendado)

Se recomienda usar un entorno virtual para no afectar al resto del sistema:

```
python3 -m venv venv
source venv/bin/activate      # Linux / macOS
venv\Scripts\activate        # Windows
```

⚠ Verás que el prompt de la terminal cambia para indicar que el entorno virtual está activo.

3.3 Instalar dependencias

```
pip install -r requirements.txt
```

O bien instalar manualmente:

```
pip install numpy pandas matplotlib scikit-learn
```

4. Ejecución de la aplicación

4.1 Ejecución normal

Desde la carpeta raíz del proyecto, ejecuta:

```
python3 clasificador_salud.py
```

⚠ En Windows puede ser 'python' en lugar de 'python3'.

4.2 Ejecución desde otra carpeta

El script está diseñado para poder ejecutarse desde cualquier directorio:

```
python3 /ruta/al/proyecto/clasificador_salud.py
```

Los archivos generados (dataset y gráficas) se crearán siempre dentro de la carpeta del proyecto, independientemente de desde dónde se ejecute.

4.3 Primera ejecución

En la primera ejecución el script intentará descargar el dataset automáticamente. Si no hay conexión a internet, coloca el archivo diabetes.csv en la carpeta raíz del proyecto antes de ejecutar.

5. Salida esperada en consola

Al ejecutar el script correctamente verás en pantalla las siguientes secciones en orden:

1. HITO 1 — INGESTA DE DATOS: confirmación de carga del CSV, número de filas y columnas, y resumen estadístico.
2. HITO 2 — PREPROCESAMIENTO: valores nulos detectados por columna y mediana usada para imputar cada una.
3. HITO 2 — ANÁLISIS EXPLORATORIO (EDA): rutas de las 3 gráficas generadas.
4. HITO 3 — ENTRENAMIENTO Y EVALUACIÓN: métricas de ambos modelos (accuracy, precision, recall, F1) y el mejor modelo seleccionado.
5. PIPELINE COMPLETADO: confirmación de finalización y ruta de las gráficas.

6. Archivos generados

Archivo	Ubicación	Descripción
diabetes.csv	Raíz del proyecto	Dataset clínico con 768 pacientes y 9 variables
01_distribuciones.png	graficas/	Histogramas de Glucosa, IMC, Edad y Presión por clase
02_dispersion_glucosa_edad.png	graficas/	Diagrama de dispersión Edad vs Glucosa por clase
03_matriz_correlacion.png	graficas/	Mapa de calor de correlación entre todas las variables
04_matriz_confusion.png	graficas/	Matriz de confusión del mejor modelo

7. Interpretación de los resultados

7.1 Gráficas EDA

- Histogramas: Si las distribuciones de una variable difieren claramente entre clases (azul = sano, rojo = diabetes), esa variable es un buen predictor. La glucosa es el ejemplo más claro.
- Dispersión Glucosa/Edad: Los puntos rojos (diabetes) tienden a concentrarse en la zona de glucosa alta y mayor edad.
- Matriz de correlación: Valores cercanos a 1 o -1 indican correlación fuerte. La glucosa tiene la mayor correlación con el diagnóstico (≈ 0.49).

7.2 Métricas del modelo

Métrica	Qué mide	Ideal
Accuracy	% de predicciones correctas en total	Cuanto más alto mejor
Precision	De los que predijo positivos, cuántos lo eran realmente	Cuanto más alto mejor
Recall	De los positivos reales, cuántos detectó	Crítico en contexto médico
F1-score	Media armónica de precision y recall	Cuanto más alto mejor

⚠ En un contexto médico, el recall de la clase 'Con diabetes' es la métrica más importante: un falso negativo (no detectar diabetes cuando existe) es más peligroso que un falso positivo.

8. Solución de problemas frecuentes

Error	Causa probable	Solución
ModuleNotFoundError: No module named 'pandas'	Dependencias no instaladas	Ejecutar: <code>pip install -r requirements.txt</code>
FileNotFoundError: diabetes.csv	Sin conexión y sin CSV local	Descargar el CSV de Kaggle y colocarlo en la raíz
python: command not found	En Linux/macOS el comando es python3	Usar python3 en lugar de python
Las gráficas no se abren	El script las guarda pero no las muestra	Abrir manualmente la carpeta graficas/

9. Desinstalación

Para eliminar la aplicación simplemente borra la carpeta del proyecto. Si usaste entorno virtual, no quedan rastros en el sistema.

```
rm -rf P3_clasificador_salud_ml/      # Linux / macOS
rmdir /s P3_clasificador_salud_ml    # Windows
```

10. Contacto

Autor: Salvador Martínez Bolinches

Centro: IES Font de Sant Lluís

Repositorio: https://github.com/SalvaIES/P3_clasificador_salud_ml